LuzViva

Big Data Architecture & Data Integration
Pipeline de iluminação pública: Airflow 3 + Databricks (Bronze, Prata, Ouro)

01 · Integrantes

Nome	RM
Caíque Walter Silva	RM550693
Guilherme Nobre Bernardo	RM98604
Guilherme Monteiro Espim	RM99499
João Paulo Fonseca Zamperlini	RM99279
Matheus José de Lima Costa	RM551157

Repositório público: https://github.com/GS-LuzViva/big-data-architecture-luzviva

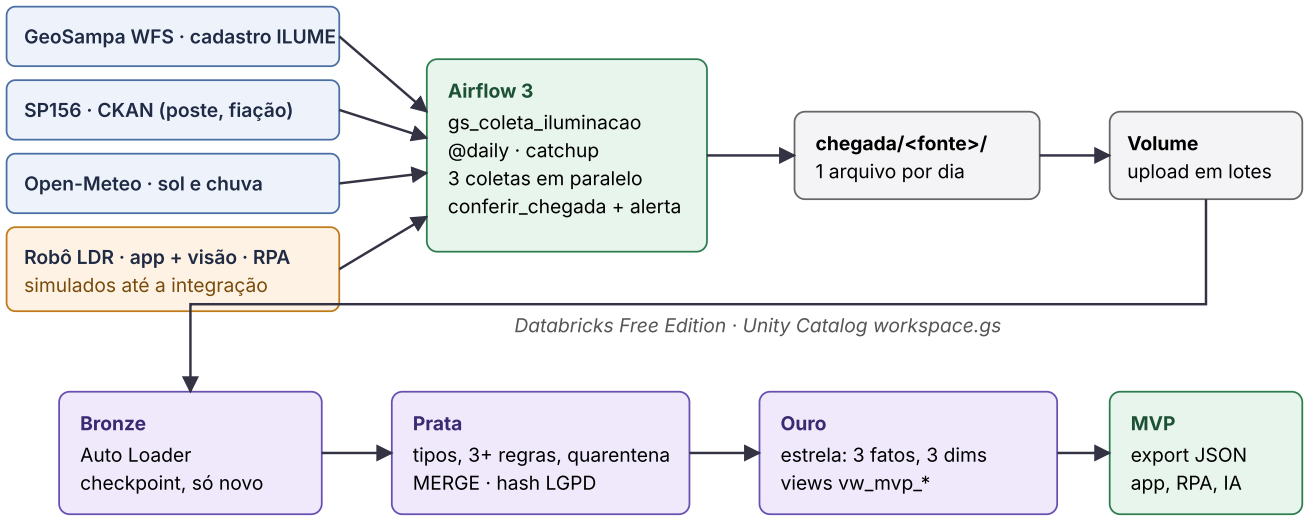
02 · Produto e perguntas do MVP

> Um robô mede a luz sob cada poste à noite, o cidadão manda foto pelo app e a visão computacional classifica; o pipeline cruza tudo com o cadastro real da ILUME e entrega ao gestor quais luminárias estão apagadas, onde e em que ordem atender, e ao RPA os chamados a abrir.

1. Como está a iluminação de cada subprefeitura do piloto agora? (Q1)
2. Quais luminárias a equipe de campo deve atender primeiro? (Q2)
3. Quantas falhas o sistema achou antes de alguém reclamar? (Q3, impacto)
4. Quanto tempo a cidade leva hoje para resolver poste e fiação pelo SP156? (Q4, linha de base real)
5. Quando a visão diz "apagada", o robô confirma? (Q5, IA responsável)
6. Depois que o chamado é aberto, quanto tempo leva o reparo, e o robô confirma a luz de volta? (Q6, impacto)

Piloto em três áreas: Sé, Pinheiros e Campo Limpo (47.736 pontos de iluminação do cadastro ILUME), de 01 a 12/11/2026.

03 · Diagrama do fluxo



O Databricks Free Edition não aceita conexão do Airflow; por isso a ponte é a pasta `chegada/`, enviada ao Volume `workspace.gs.chegada` em lotes. Dependências do DAG: `inicio >> [luminarias, sp156, clima]`; `luminarias >> [medicoes_robo, ocorrencias_app]`; `medicoes_robo >> chamados_rpa`; todas `>> conferir_chegada`.

04 · Fontes de dados

Fonte	Origem	Tipo	Formato	Frequência	Volume no piloto
luminarias	GeoSampa WFS `geoportal:iluminacao_publica` (SMUL/ILUME)	externa real	GeoJSON paginado	diária	47.736 pontos
sp156	Portal de Dados Abertos SP, `dados-do-sp156` (CKAN)	externa real	CSV Latin-1 ;	diária (arquivo trimestral, cache)	1.113 pedidos de poste/fiação
clima	Open-Meteo `/v1/forecast`	externa real	JSON	diária	3 pontos
medicoes_robo	robô LDR (Maker Lab)	própria, simulada	JSON	diária (rota noturna)	150 a 260/noite
ocorrencias_app	app + visão computacional	própria, simulada	JSON	diária	8 a 18 fotos/dia
chamados_rpa	robô de RPA	própria, simulada	JSON	diária	322 chamados

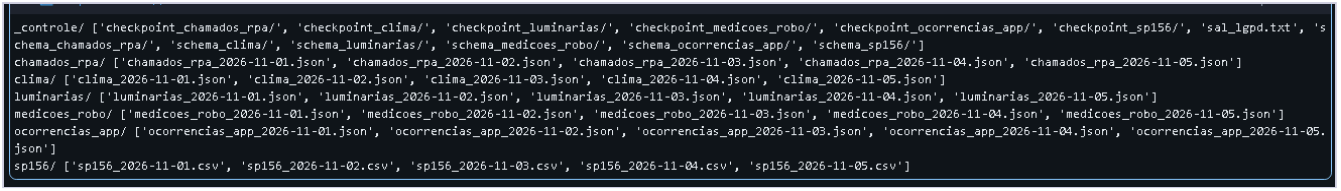
Por que simular. Robô, visão e RPA ficam prontos na mesma janela de entrega. O simulador gera o mesmo formato do contrato (`docs/contrato_mvp.md`), ancorado em postes reais do cadastro, com ~6% de sujeira proposital para as regras da Prata terem o que barrar. Quando o dado real chegar, ele cai na mesma pasta e nada muda dali em diante.

Achados nas fontes reais. (1) Lâmpada apagada quase não aparece no SP156 aberto: a cidade tem 663 mil pontos cadastrados e nenhum dado aberto de quais estão apagados, que é a lacuna do produto. (2) O SP156 muda o formato da data entre arquivos (dd/MM no 2º trimestre, MM/dd no 3º); a Prata detecta por arquivo. (3) O SP156 não tem protocolo: a chave é um hash dos campos estáveis. (4) Na zona do piloto o poste vizinho fica a 12,7 m (mediana), menos que o erro do GPS de celular: o pipeline liga foto e medição ao poste pela placa ILUME e usa o GPS só como reserva.

05 · Requisitos 01 a 09

Requisito 01 · Fontes (≥ 2, ≥ 1 externa real)

Três fontes externas reais (GeoSampa, SP156, Open-Meteo) e três próprias. Configuração em `dags/coletores/temas.py`; descrição em `docs/fontes.md`.



Volume `workspace.gs.chegada`: as 6 fontes, um arquivo por dia (lotes 1 e 2).

Requisito 02 · DAG agendado gravando em chegada/

`gs_coleta_iluminacao`, `@daily`, `catchup=True` desde 01/11, grava `chegada/<fonte>/<fonte>_AAAA-MM-DD`, com 2 retries e alerta de falha.

Prints na seção 06 (Grid com 12 execuções diárias, 0 falhas).

Requisito 03 · Paralelismo, verificação e Variables

As três fontes externas rodam em paralelo; `conferir_chegada` valida que todo arquivo chegou; caminho e webhook ficam nas Variables `gs_chegada` e `gs_webhook_url`, fora do código.

Print na seção 06 (visão Graph).

Requisito 04 · Dois ou mais lotes ao Volume

Três lotes de dias diferentes: 01–03 e 04–05 (05/11) e 06–12 (12/11).

Print na seção 07 (contagens por lote).

Requisito 05 · Bronze incremental sem duplicar

Auto Loader com checkpoint por fonte: só arquivo novo entra; arquivo reenviado é ignorado. Contagens em `gs.controle_cargas`.

Prints na seção 07.

Requisito 06 · Prata: tipos, MERGE e regras com contagem

JSON do envelope aberto com schema do contrato, tipos convertidos, regras de qualidade por tabela (21 no total) com linhas barradas indo para `prata_quarentena`, e MERGE pela chave de negócio.



```
08:14 PM (2m)                                                                    3

# Luminárias primeiro: medições e ocorrências se casam com elas
processar("luminarias", il.luminarias_para_prata(b("luminarias")), il.regras_luminarias(), ["id_luminaria"])
lums = spark.table("workspace.gs.prata_luminarias")

processar("medicoes", il.medicoes_para_prata(b("medicoes_robo"), lums), il.regras_medicoes(), ["id_medicao"])
processar("ocorrencias", il.ocorrencias_para_prata(b("ocorrencias_app"), lums, SAL),
          il.regras_ocorrencias(), ["id_ocorrencia"])
processar("sp156", il.sp156_para_prata(b("sp156")), il.regras_sp156(), ["id_pedido"])
processar("clima", il.clima_para_prata(b("clima")), il.regras_clima(), ["subprefeitura", "data"])
processar("chamados", il.chamados_para_prata(b("chamados_rpa"), lums), il.regras_chamados(), ["id_chamado"])

See performance (50)                                              Checked for improvements

lums: pyspark.sql.connect.dataframe.DataFrame = [id_luminaria: long, placa: string ... 11 more fields]

luminarias {'tabela': 'workspace.gs.prata_luminarias', 'antes': 47736, 'depois': 47736, 'novas': 0} [('id_presente', 0), ('coordenada_em_sp', 0), ('placa_presente', 0)]
medicoes {'tabela': 'workspace.gs.prata_medicoes', 'antes': 546, 'depois': 1009, 'novas': 463} [('lux_valido', 26), ('coordenada_em_sp', 14), ('medicao_noturna', 28), ('perto_de_luminari
a', 14)]
ocorrencias {'tabela': 'workspace.gs.prata_ocorrencias', 'antes': 111, 'depois': 134, 'novas': 23} [('categoria_obrigatoria', 3), ('coordenada_em_sp', 2), ('confianca_valida', 3), ('data
_nao_futura', 0)]
sp156 {'tabela': 'workspace.gs.prata_sp156', 'antes': 1113, 'depois': 1113, 'novas': 0} [('data_abertura_valida', 0), ('coordenada_em_sp', 0), ('finalizacao_coerente', 0)]
clima {'tabela': 'workspace.gs.prata_clima', 'antes': 9, 'depois': 15, 'novas': 6} [('data_presente', 0), ('sol_coerente', 0), ('chuva_nao_negativa', 0)]
chamados {'tabela': 'workspace.gs.prata_chamados', 'antes': 90, 'depois': 171, 'novas': 81} [('status_conhecido', 0), ('prioridade_valida', 0), ('conclusao_coerente', 0), ('placa_no_cada
stro', 0)]
{'tabela': 'workspace.gs.prata_chamados',
 'antes': 90,
 'depois': 171,
 'novas': 81}
```

Prata: antes, depois e novas por tabela após o MERGE.



```
08:14 PM (4s)                                                                    4                                                    SQL

%sql
-- Print para o relatório: total barrado por regra na última execução
SELECT tabela, regra, descricao, linhas_avaliadas, linhas_barradas,
       round(100 * linhas_barradas / linhas_avaliadas, 2) AS pct_barrado
FROM workspace.gs.controle_qualidade
QUALIFY executado_em = max(executado_em) OVER (PARTITION BY tabela)
ORDER BY tabela, regra

See performance (1)                                               Checked for improvements
```

Table +

	tabela	regra	descricao	linhas_avaliadas	linhas_barradas	pct_barrado
1	prata_chamad...	conclusao_coere...	Concluído tem data de conclusão e ela não antecede a a...	171	0	0
2	prata_chamad...	placa_no_cadastro	Chamado aponta para uma luminária do cadastro ILUME	171	0	0
3	prata_chamad...	prioridade_valida	Prioridade entre 0 e 100	171	0	0
4	prata_chamad...	status_conhecido	Status dentro do contrato	171	0	0
5	prata_clima	chuva_nao_negat...	Chuva >= 0 mm	15	0	0
6	prata_clima	data_presente	Dia informado	15	0	0
7	prata_clima	sol_coerente	Pôr do sol depois do nascer	15	0	0
8	prata_luminar...	coordenada_em_sp	Coordenada presente e dentro do município	47736	0	0
9	prata_luminar...	id_presente	Ponto sem identificador ILUME não vira dimensão	47736	0	0
10	prata_luminar...	placa_presente	Sem placa o chamado não chega à equipe de campo	47736	0	0
11	prata_medicoes	coordenada_em_sp	GPS com fix e dentro do município	1077	14	1.3
12	prata_medicoes	lux_valido	Leitura do LDR não pode ser negativa	1077	26	2.41
13	prata_medicoes	medicao_noturna	Iluminância de rua só vale entre 18h e 6h	1077	28	2.6
14	prata_medicoes	perto_de_luminaria	A até 30 m de um ponto do cadastro ILUME	1077	14	1.3
15	prata_ocorren...	categoria_obriga...	Ocorrência precisa ter categoria	142	3	2.11

21 rows 3.928s runtime Refreshed at 11/5/26, 8:14 PM (17m ago)

`gs.controle_qualidade` *: regras e linhas barradas (parte 1).*



```
%sql
-- Print para o relatório: total barrado por regra na última execução
SELECT tabela, regra, descricao, linhas_avaliadas, linhas_barradas,
       round(100 * linhas_barradas / linhas_avaliadas, 2) AS pct_barrado
FROM workspace.gs.controle_qualidade
QUALIFY executado_em = max(executado_em) OVER (PARTITION BY tabela)
ORDER BY tabela, regra
```

08:14 PM (4s) · See performance (1) · Checked for improvements

Table

	tabela	regra	descricao	linhas_avaliadas	linhas_barradas	pct_barrado
7	prata_clima	sol_coerente	Pôr do sol depois do nascer	15	0	0
8	prata_luminar...	coordenada_em_sp	Coordenada presente e dentro do município	47736	0	0
9	prata_luminar...	id_presente	Ponto sem identificador ILUME não vira dimensão	47736	0	0
10	prata_luminar...	placa_presente	Sem placa o chamado não chega à equipe de campo	47736	0	0
11	prata_medicoes	coordenada_em_sp	GPS com fix e dentro do município	1077	14	1.3
12	prata_medicoes	lux_valido	Leitura do LDR não pode ser negativa	1077	26	2.41
13	prata_medicoes	medicao_noturna	Iluminância de rua só vale entre 18h e 6h	1077	28	2.6
14	prata_medicoes	perto_de_luminaria	A até 30 m de um ponto do cadastro ILUME	1077	14	1.3
15	prata_ocorren...	categoria_obriga...	Ocorrência precisa ter categoria	142	3	2.11
16	prata_ocorren...	confianca_valida	Confiança da visão entre 0 e 1	142	3	2.11
17	prata_ocorren...	coordenada_em_sp	Coordenada dentro do município	142	2	1.41
18	prata_ocorren...	data_nao_futura	Data não passa do dia seguinte à coleta	142	0	0
19	prata_sp156	coordenada_em_sp	Latitude/longitude dentro do município	1113	0	0
20	prata_sp156	data_abertura_va...	Abertura presente, legível e não futura	1113	0	0
21	prata_sp156	finalizacao_coere...	Finalização ausente ou não anterior à abertura	1113	0	0

21 rows · 3.928s runtime · Refreshed at 11/5/26, 8:14 PM (18m ago)

`gs.controle_qualidade`: regras e linhas barradas (parte 2).

Requisito 07 · Ouro (fato e dimensões) e 5 SQL

Modelo estrela: `fato_inspecao`, `fato_ocorrencia`, `fato_chamado` com `dim_luminaria`, `dim_regiao`, `dim_tempo`. Seis consultas interpretadas na seção 08.

PRINT
`prints/r07_ouro_catalogo.png`

Catálogo `workspace.gs` com as tabelas Bronze, Prata e Ouro e as views do MVP.

Requisito 08 · LGPD na Ouro e uso pelo MVP

Nome, e-mail e telefone do cidadão viram `cidadao_hash` (SHA-256 com sal guardado fora do repositório); coordenada generalizada para ~110 m; as views `vw_mvp_*` não expõem nem o pseudônimo. O notebook 05 exporta as views em JSON para a API do app.



Export das views do MVP: mapa (47.736), fila de manutenção (239) e painel (3).

PRINT
`prints/r08_app_mvp.png`

Tela do app LuzViva exibindo os dados exportados.

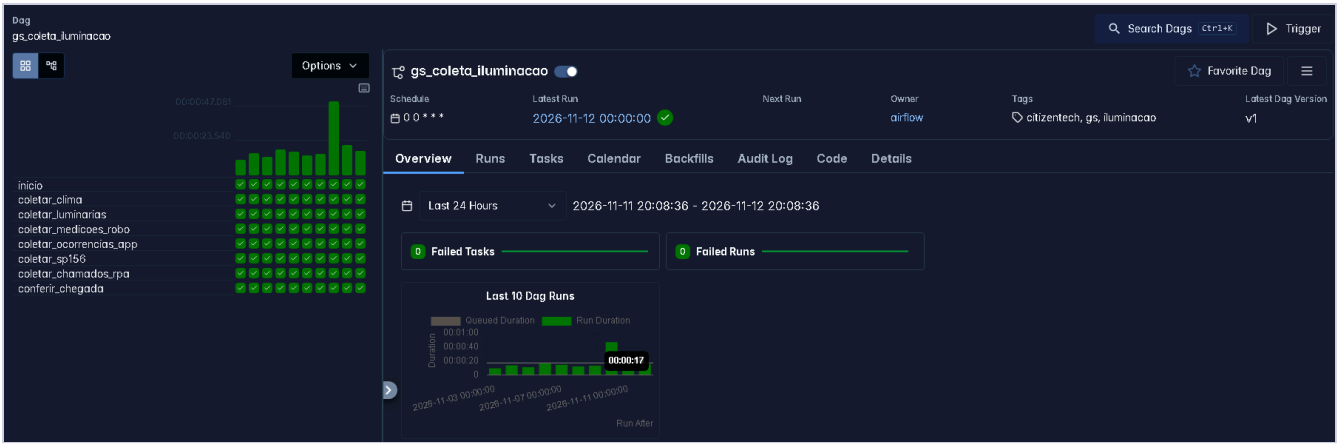
Requisito 09 · README e organização

README com integrantes, arquitetura, passo a passo e mapa dos requisitos; pastas `dags/`, `databricks/`, `docs/`, `amostras/`, `tests/` (28 testes automatizados).

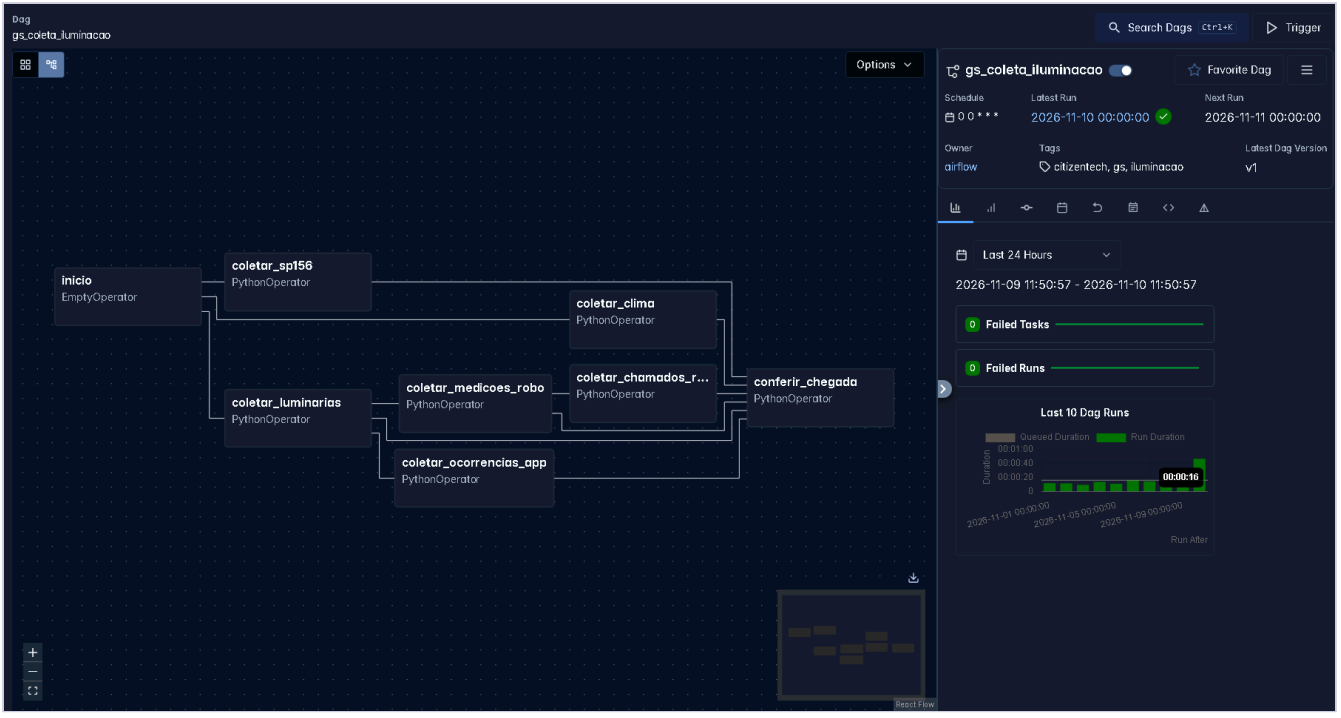
PRINT
`prints/r09_github.png`

Repositório público no GitHub.

06 · Airflow



Visão Grid: execuções diárias de 01 a 12/11/2026, todas concluídas.



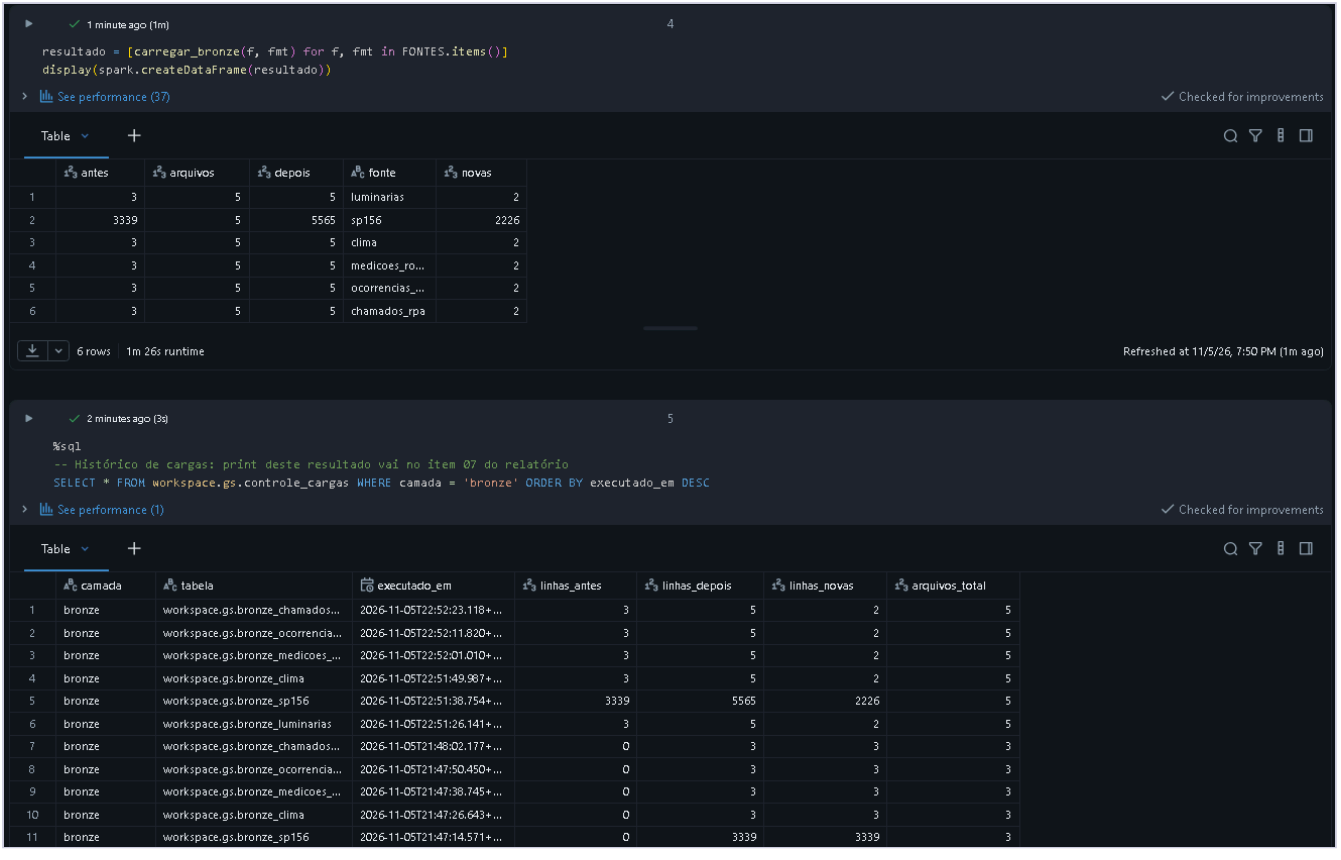
Visão Graph: `inicio` dispara as três fontes externas em paralelo; as simuladas esperam o cadastro de luminárias; `conferir_chegada` fecha o dia.

07 · Contagens da Bronze

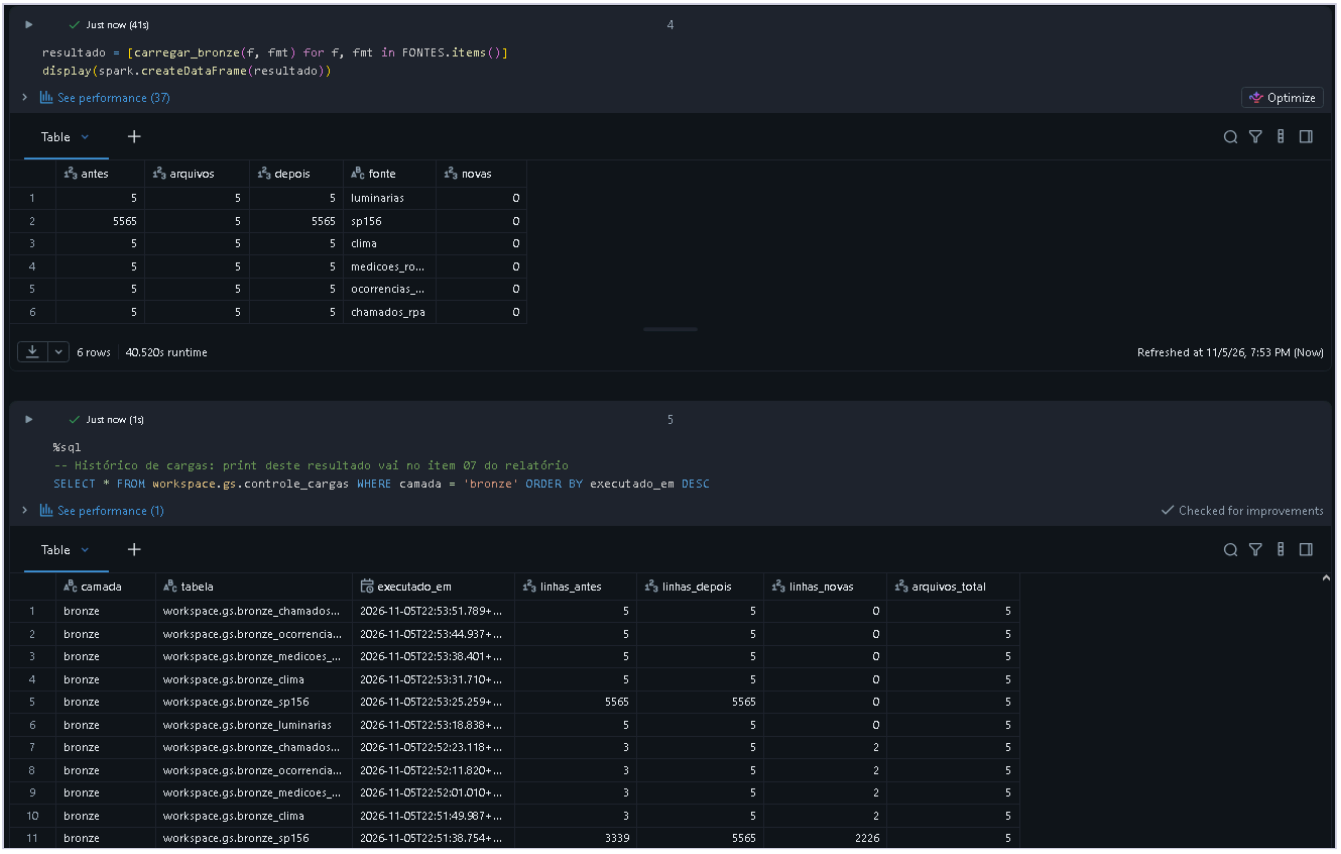
Rodada	Arquivos por fonte	JSON (cada fonte)	sp156 (linhas)	Leitura
1º lote (01–03)	3	0 → 3	0 → 3.339	carga inicial
2º lote (04–05)	5	3 → 5 (+2)	3.339 → 5.565 (+2.226)	só os arquivos novos entram
reexecução sem lote novo	5	5 → 5 (0)	5.565 → 5.565 (0)	não duplica



Volume com o 2º lote: 5 arquivos por pasta.



Bronze após o 2º lote: só as linhas novas entraram.



Bronze executada de novo sem arquivo novo: `novas = 0` em todas as fontes; histórico em `gs.controle_cargas`.

Bronze × Prata. A Bronze do SP156 guarda o recorte trimestral uma vez por dia de coleta, como chegou; a Prata fica com 1.113 pedidos únicos, porque o MERGE pela chave hash descarta a repetição. Os arquivos de luminárias 01 a 03 foram reenviados por engano e não entraram de novo: o checkpoint do Auto Loader reconhece arquivo já lido.

08 · Consultas SQL e interpretação

Seis consultas em `databricks/04_consultas.sql` sobre a Ouro, 12 dias de dado (01 a 12/11/2026).

Q1 · Situação por subprefeitura



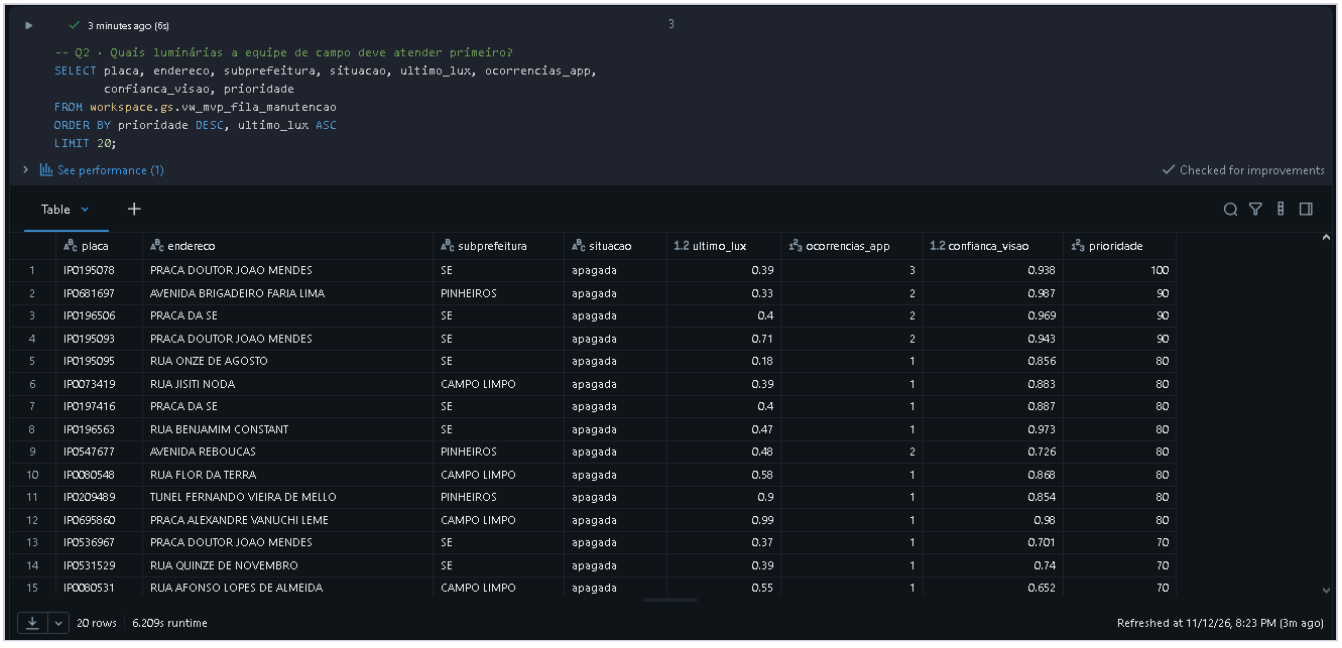
```sql
-- Q1 · Qual a situação da iluminação em cada subprefeitura do piloto agora?
-- (última medição de cada luminária inspecionada)
SELECT subprefeitura, luminarias_cadastradas, luminarias_inspecionadas,
       apagadas, insuficientes, pct_com_falha
FROM workspace.gs.vw_mvp_painel_subprefeitura
ORDER BY pct_com_falha DESC;
```

	subprefeitura	luminarias_cadastradas	luminarias_inspecionadas	apagadas	insuficientes	pct_com_falha
1	SE	17035	538	23	53	14.1
2	CAMPO LIMPO	16911	516	34	39	14.1
3	PINHEIROS	13790	431	21	39	13.9

Q1 · Situação por subprefeitura

> 13,9% a 14,1% das luminárias inspecionadas estão com falha nas três áreas (1.485 inspecionadas: 78 apagadas e 131 insuficientes). Uma em cada sete luminárias inspecionadas não ilumina o mínimo, e a proporção é parecida no centro (Sé) e na periferia (Campo Limpo).

Q2 · Fila de manutenção



```sql
-- Q2 · Quais luminárias a equipe de campo deve atender primeiro?
SELECT placa, endereco, subprefeitura, situacao, ultimo_lux, ocorrencias_app,
       confianca_visao, prioridade
FROM workspace.gs.vw_mvp_fila_manutencao
ORDER BY prioridade DESC, ultimo_lux ASC
LIMIT 20;
```

	placa	endereco	subprefeitura	situacao	ultimo_lux	ocorrencias_app	confianca_visao	prioridade
1	IP0195078	PRACA DOUTOR JOAO MENDES	SE	apagada	0.39	3	0.938	100
2	IP0681697	AVENIDA BRIGADEIRO FARIA LIMA	PINHEIROS	apagada	0.33	2	0.987	90
3	IP0196506	PRACA DA SE	SE	apagada	0.4	2	0.969	90
4	IP0195093	PRACA DOUTOR JOAO MENDES	SE	apagada	0.71	2	0.943	90
5	IP0195095	RUA ONZE DE AGOSTO	SE	apagada	0.18	1	0.856	80
6	IP0073419	RUA JISITI NODA	CAMPO LIMPO	apagada	0.39	1	0.883	80
7	IP0197416	PRACA DA SE	SE	apagada	0.4	1	0.887	80
8	IP0196563	RUA BENJAMIM CONSTANT	SE	apagada	0.47	1	0.973	80
9	IP0547677	AVENIDA REBOUCAS	PINHEIROS	apagada	0.48	2	0.726	80
10	IP0080548	RUA FLOR DA TERRA	CAMPO LIMPO	apagada	0.58	1	0.868	80
11	IP0209489	TUNEL FERNANDO VIEIRA DE MELLO	PINHEIROS	apagada	0.9	1	0.854	80
12	IP0695860	PRACA ALEXANDRE VANUCHI LEME	CAMPO LIMPO	apagada	0.99	1	0.98	80
13	IP0536967	PRACA DOUTOR JOAO MENDES	SE	apagada	0.37	1	0.701	70
14	IP0531529	RUA QUINZE DE NOVEMBRO	SE	apagada	0.39	1	0.74	70
15	IP0080531	RUA AFONSO LOPES DE ALMEIDA	CAMPO LIMPO	apagada	0.55	1	0.652	70

Q2 · Fila de manutenção

> A prioridade soma evidências: apagada vale 60, cada relato de cidadão +10 (máx. 30) e a visão com confiança ≥ 0,8 +10. O topo (100, Praça Doutor João Mendes, placa IP0195078) tem robô, três relatos e visão concordando. A placa vai pronta para a equipe da ILUME.

Q3 · Falhas achadas antes da reclamação (impacto)



```sql
-- Q3 · IMPACTO: quantas falhas o sistema achou antes de algum cidadão reclamar,
-- e quantas horas de rua no escuro isso representa por noite?
WITH falhas AS (
  SELECT m.id_luminaria, m.subprefeitura, m.situacao, m.ocorrencias_app
  FROM workspace.gs.vw_mvp_mapa_luminarias m
  WHERE m.situacao IN ('apagada', 'insuficiente')),
escuro AS (
  SELECT subprefeitura, avg(horas_escuridao) AS horas_escuridao_media
  FROM workspace.gs.prata_clima GROUP BY subprefeitura)
SELECT f.subprefeitura,
       count(*)                                          AS falhas_detectadas,
       sum(CASE WHEN f.ocorrencias_app = 0 THEN 1 ELSE 0 END) AS falhas_sem_nenhum_relato,
       round(100 * sum(CASE WHEN f.ocorrencias_app = 0 THEN 1 ELSE 0 END) / count(*), 1)
                                                         AS pct_deteccao_proativa,
       round(sum(CASE WHEN f.situacao = 'apagada' THEN 1 ELSE 0 END)
             * coalesce(max(e.horas_escuridao_media), 11), 0) AS horas_luminaria_no_escuro_por_noite
FROM falhas f
LEFT JOIN escuro e ON e.subprefeitura = f.subprefeitura
GROUP BY f.subprefeitura
ORDER BY falhas_sem_nenhum_relato DESC;
```

3 minutes ago (4s) · See performance (1) · Checked for improvements

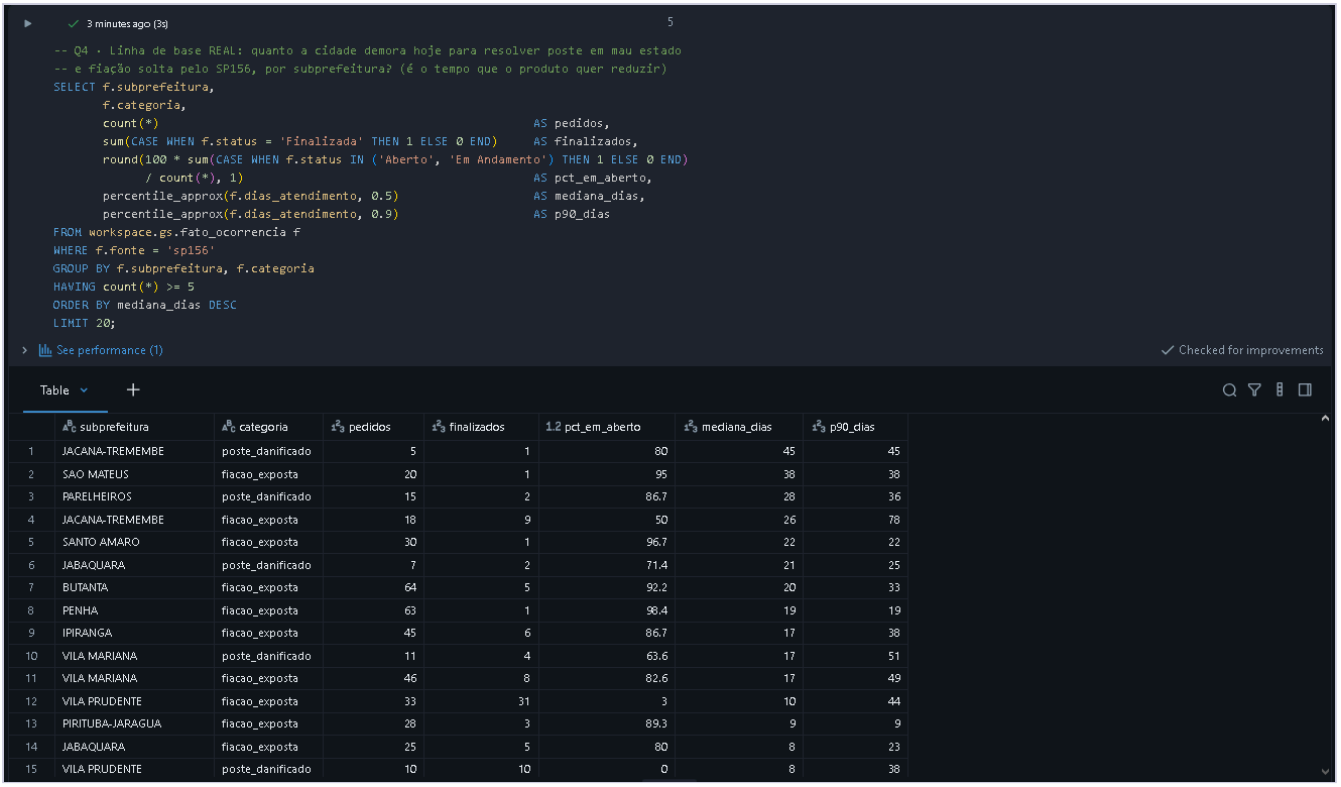
Table

	subprefeitura	falhas_detectadas	falhas_sem_nenhum_relato	pct_deteccao_proativa	horas_luminaria_no_escuro_por_noite
1	SE	76	56	73.7	251
2	CAMPO LIMPO	73	54	74	370
3	PINHEIROS	60	50	83.3	229

Q3 · Falhas achadas antes da reclamação (impacto)

> 73,7% a 83,3% das falhas encontradas pelo robô não tinham nenhum relato de cidadão. Somadas, as luminárias apagadas representam 850 horas de rua no escuro por noite. Ressalva: o volume de fotos é simulado; o número real depende da adesão ao app.

Q4 · Linha de base real no SP156



```
-- Q4 · Linha de base REAL: quanto a cidade demora hoje para resolver poste em mau estado
-- e fiação solta pelo SP156, por subprefeitura? (é o tempo que o produto quer reduzir)
SELECT f.subprefeitura,
       f.categoria,
       count(*)                                                    AS pedidos,
       sum(CASE WHEN f.status = 'Finalizada' THEN 1 ELSE 0 END)    AS finalizados,
       round(100 * sum(CASE WHEN f.status IN ('Aberto', 'Em Andamento') THEN 1 ELSE 0 END)
             / count(*), 1)                                        AS pct_em_aberto,
       percentile_approx(f.dias_atendimento, 0.5)                  AS mediana_dias,
       percentile_approx(f.dias_atendimento, 0.9)                  AS p90_dias
FROM workspace.gs.fato_ocorrencia f
WHERE f.fonte = 'sp156'
GROUP BY f.subprefeitura, f.categoria
HAVING count(*) >= 5
ORDER BY mediana_dias DESC
LIMIT 20;
```

	subprefeitura	categoria	pedidos	finalizados	pct_em_aberto	mediana_dias	p90_dias
1	JACANA-TREMEMBE	poste_danificado	5	1	80	45	45
2	SAO MATEUS	fiacao_exposta	20	1	95	38	38
3	PARELHEIROS	poste_danificado	15	2	86.7	28	36
4	JACANA-TREMEMBE	fiacao_exposta	18	9	50	26	78
5	SANTO AMARO	fiacao_exposta	30	1	96.7	22	22
6	JABAQUARA	poste_danificado	7	2	71.4	21	25
7	BUTANTA	fiacao_exposta	64	5	92.2	20	33
8	PENHA	fiacao_exposta	63	1	98.4	19	19
9	IPIRANGA	fiacao_exposta	45	6	86.7	17	38
10	VILA MARIANA	poste_danificado	11	4	63.6	17	51
11	VILA MARIANA	fiacao_exposta	46	8	82.6	17	49
12	VILA PRUDENTE	fiacao_exposta	33	31	3	10	44
13	PIRITUBA-JARAGUA	fiacao_exposta	28	3	89.3	9	9
14	JABAQUARA	fiacao_exposta	25	5	80	8	23
15	VILA PRUDENTE	poste_danificado	10	10	0	8	38

Q4 · Linha de base real no SP156

> Dado real: pedidos de poste em mau estado e fiação solta levam de 8 a 45 dias (mediana) conforme a subprefeitura, e em várias mais de 80% seguem em aberto (Penha 98,4%, Santo Amaro 96,7%). Hoje a cidade leva semanas; o robô detecta em até três noites. Atenção: "finalizada" no SP156 pode significar encaminhada à concessionária.

Q5 · A visão confirma? (IA responsável)



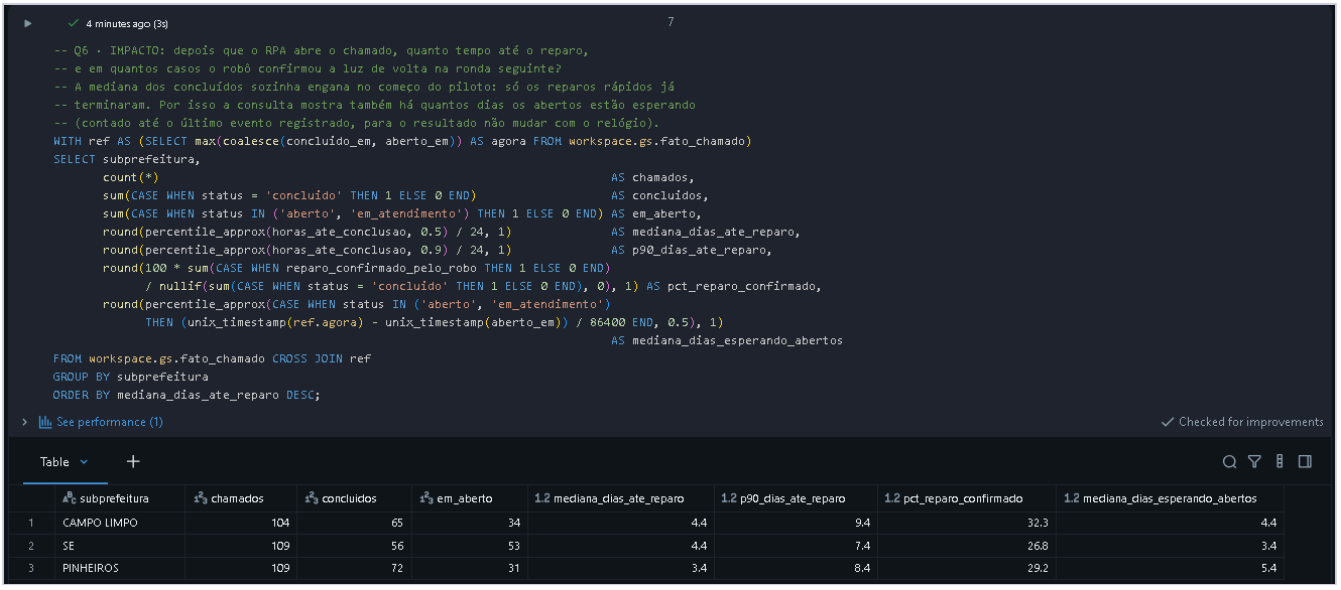
```sql
-- Q5 · IA responsável: quando a visão diz "luminária apagada", o robô confirma?
-- Cada foto é comparada com a medição LDR da MESMA luminária mais próxima no tempo
-- (até 3 dias antes ou depois): comparar com a última medição puniria a visão por um
-- poste que já foi consertado depois da foto.
WITH alegacoes AS (
  SELECT o.id_ocorrencia, o.id_luminaria,
         to_date(CAST(o.data_key AS STRING), 'yyyyMMdd') AS dia_foto,
         CASE WHEN o.confianca_visao >= 0.9 THEN '0.90+'
              WHEN o.confianca_visao >= 0.8 THEN '0.80-0.89'
              WHEN o.confianca_visao >= 0.6 THEN '0.60-0.79'
              ELSE '<0.60' END AS faixa_confianca
  FROM workspace.gs.fato_ocorrencia o
  WHERE o.fonte = 'app' AND o.categoria = 'luminaria_apagada' AND o.id_luminaria IS NOT NULL),
pares AS (
  SELECT a.faixa_confianca, i.situacao,
         row_number() OVER (PARTITION BY a.id_ocorrencia
                            ORDER BY abs(datediff(to_date(i.data_hora), a.dia_foto)), i.data_hora) AS rn
  FROM alegacoes a
  JOIN workspace.gs.fato_inspecao i
    ON i.id_luminaria = a.id_luminaria
   AND abs(datediff(to_date(i.data_hora), a.dia_foto)) <= 3)
SELECT faixa_confianca,
       count(*)                                                                  AS alegacoes_com_medicao,
       sum(CASE WHEN situacao IN ('apagada', 'insuficiente') THEN 1 ELSE 0 END)  AS confirmadas_pelo_robo,
       round(100 * sum(CASE WHEN situacao IN ('apagada', 'insuficiente') THEN 1 ELSE 0 END)
             / count(*), 1)                                                      AS precisao_pct
FROM pares
WHERE rn = 1
GROUP BY faixa_confianca
ORDER BY faixa_confianca DESC;
```

	faixa_confianca	alegacoes_com_medicao	confirmadas_pelo_robo	precisao_pct
1	<0.60	1	0	0
2	0.90+	11	10	90.9
3	0.80-0.89	14	12	85.7
4	0.60-0.79	27	19	70.4

Q5 · A visão confirma? (IA responsável)

> A precisão da visão sobe com a confiança: 0% abaixo de 0,60 (1 caso), 70,4% entre 0,60 e 0,79 (27), 85,7% entre 0,80 e 0,89 (14) e 90,9% acima de 0,90 (11). Por isso a prioridade só soma pontos com confiança ≥ 0,8, e abaixo disso a foto não abre chamado sozinha: o robô confirma antes.

Q6 · Tempo até o reparo (impacto)



```sql
-- Q6 · IMPACTO: depois que o RPA abre o chamado, quanto tempo até o reparo,
-- e em quantos casos o robô confirmou a luz de volta na ronda seguinte?
-- A mediana dos concluídos sozinha engana no começo do piloto: só os reparos rápidos já
-- terminaram. Por isso a consulta mostra também há quantos dias os abertos estão esperando
-- (contado até o último evento registrado, para o resultado não mudar com o relógio).
WITH ref AS (SELECT max(coalesce(concluido_em, aberto_em)) AS agora FROM workspace.gs.fato_chamado)
SELECT subprefeitura,
       count(*)                                                          AS chamados,
       sum(CASE WHEN status = 'concluido' THEN 1 ELSE 0 END)             AS concluidos,
       sum(CASE WHEN status IN ('aberto', 'em_atendimento') THEN 1 ELSE 0 END) AS em_aberto,
       round(percentile_approx(horas_ate_conclusao, 0.5) / 24, 1)        AS mediana_dias_ate_reparo,
       round(percentile_approx(horas_ate_conclusao, 0.9) / 24, 1)        AS p90_dias_ate_reparo,
       round(100 * sum(CASE WHEN reparo_confirmado_pelo_robo THEN 1 ELSE 0 END)
             / nullif(sum(CASE WHEN status = 'concluido' THEN 1 ELSE 0 END), 0), 1) AS pct_reparo_confirmado,
       round(percentile_approx(CASE WHEN status IN ('aberto', 'em_atendimento')
             THEN (unix_timestamp(ref.agora) - unix_timestamp(aberto_em)) / 86400 END, 0.5), 1)
                                                                         AS mediana_dias_esperando_abertos
FROM workspace.gs.fato_chamado CROSS JOIN ref
GROUP BY subprefeitura
ORDER BY mediana_dias_ate_reparo DESC;
```

4 minutes ago (3s) · See performance (1) · Checked for improvements

Table

	subprefeitura	chamados	concluidos	em_aberto	mediana_dias_ate_reparo	p90_dias_ate_reparo	pct_reparo_confirmado	mediana_dias_esperando_abertos
1	CAMPO LIMPO	104	65	34	4.4	9.4	32.3	4.4
2	SE	109	56	53	4.4	7.4	26.8	3.4
3	PINHEIROS	109	72	31	3.4	8.4	29.2	5.4

Q6 · Tempo até o reparo (impacto)

> 322 chamados abertos pelo RPA; mediana de 3,4 a 4,4 dias até o reparo (p90 de 7,4 a 9,4) e 27% a 32% dos reparos já confirmados em campo pelo robô. Os chamados abertos esperam há 3,4 a 5,4 dias (mediana), então a mediana dos concluídos não esconde uma fila parada. Comparado com a Q4: semanas no canal atual contra dias com o ciclo robô → RPA → equipe.

09 · Conclusão

O que funcionou. Coleta diária automática de três fontes públicas reais e três próprias, com reprocessamento seguro (Bronze não duplica, Prata faz MERGE), 21 regras de qualidade com quarentena, modelo estrela na Ouro e entrega ao app por views sem dado pessoal. As consultas sustentam o argumento do produto: a maior parte das falhas não é reclamada (Q3) e o canal atual leva semanas (Q4), enquanto o ciclo do LuzViva fecha em dias e é conferido em campo (Q6), com a IA usada só onde é confiável (Q5).

Limites. Robô, fotos e chamados são simulados até a integração com os componentes do grupo; o SP156 aberto quase não registra lâmpada apagada, então a linha de base usa poste e fiação; o Free Edition exige upload manual dos lotes.

Próximo passo. Trocar as fontes simuladas pelos dados reais do robô, do app e do RPA (mesmo contrato), pedir à ILUME o histórico de chamados de lâmpada apagada e agendar os notebooks num Job.

Repositório: https://github.com/GS-LuzViva/big-data-architecture-luzviva